机器学习课程实验报告

实验题目：基于 Fashion-MNIST 的 MLP 图像分类及优化器性能比较

学生：汤鑫

日期：2026-10-27

机器学习优化器比较实验报告

1 实验题目

基于 Fashion-MNIST 的 MLP 图像分类及优化器性能比较

2 实验目的

本实验旨在通过 Fashion-MNIST 图像分类任务，达到以下目标：

1. 掌握基于 PyTorch 的神经网络训练完整流程（数据加载、模型定义、训练循环、评估与结果保存）。
2. 理解 SGD、Momentum、RMSProp、Adam 四种常见优化器的基本原理与差异。
3. 在相同模型与数据条件下，比较四种优化器在测试准确率、训练损失、收敛速度与训练时间上的表现。
4. 认识学习率等超参数对优化器性能的重要影响，理解「优化器的性能不能脱离学习率单独评价」这一核心认识。
5. 通过多随机种子实验，检验单次实验结论的稳健性。

3 实验原理

3.1 Fashion-MNIST

Fashion-MNIST 是由 Zalando 发布的服装图像分类数据集，常作为手写数字数据集 MNIST 的替代基准。它包含 10 个服饰类别（T 恤、裤子、套头衫、连衣裙、外套、凉鞋、衬衫、运动鞋、包、短靴），共 70,000 张 28×28 的单通道灰度图像，其中训练集 60,000 张、测试集 10,000 张。与 MNIST 相比，Fashion-MNIST 图像之间相似度更高、更具挑战性，但规模适中、结构简单，适合用于观察不同优化器在训练过程中的行为差异。

3.2 MLP

多层感知机（Multi-Layer Perceptron，MLP）是最基本的前馈神经网络。本实验使用的模型将 28×28 的图像展平为 784 维向量，然后依次经过三个全连接层：

```
784 → Linear(784, 128) → ReLU → Linear(128, 64) → ReLU → Linear(64, 10)
```

最后一层输出 10 个类别的得分，配合 Softmax 完成多分类。

3.3 交叉熵损失

本实验采用交叉熵损失（CrossEntropyLoss），其定义为：

$$L = -\sum_i y_i \log(p_i)$$

其中

y_i

为真实标签的 one-hot 编码，

p_i

为模型预测的类别概率。交叉熵是衡量两个概率分布差异的标准方法，是多分类任务中最常用的损失函数。

3.4 SGD（随机梯度下降）

SGD 是最基础的优化算法，沿梯度负方向以固定学习率更新参数：

$$\theta_{t+1} = \theta_t - \eta g_t$$

其中

θ_t

为第

t

步的参数，

η

为学习率，

g_t

为当前批次的梯度。SGD 实现简单，但对学习率非常敏感：学习率过小收敛缓慢，过大则容易震荡甚至发散。

3.5 Momentum（动量法）

Momentum 在 SGD 基础上引入动量项，累积历史梯度方向以加速收敛并抑制震荡：

$$v_{t+1} = \mu v_t + g_t$$

$$\theta_{t+1} = \theta_t - \eta v_{t+1}$$

其中

$$\mu$$

为动量系数（本实验取 0.9）。动量使得参数在梯度方向一致时加速，在方向反复震荡时相互抵消，从而改善 SGD 的收敛行为。

3.6 RMSProp

RMSProp 是一种自适应学习率算法，通过梯度平方的指数移动平均对每个参数的学习率分别缩放：

$$E[g^2]_t = \rho E[g^2]_{t-1} + (1-\rho) g_t^2$$

$$\theta_{t+1} = \theta_t - \frac{\eta}{\sqrt{E[g^2]_t + \varepsilon}} g_t$$

其核心思想是：对梯度较大的参数降低有效学习率，对梯度较小的参数提高有效学习率，从而在参数尺度差异较大时保持平稳更新。

3.7 Adam

Adam 结合了 Momentum 与 RMSProp 的思想，同时维护梯度的一阶矩（均值）与二阶矩（平方均值）估计：

$$m_t = \beta_1 m_{t-1} + (1-\beta_1) g_t$$

$$v_t = \beta_2 v_{t-1} + (1-\beta_2) g_t^2$$

由于

$$m_t$$

、

$$v_t$$

初始化为零，早期估计会偏向零，Adam 通过偏差修正进行校正：

$$\hat{m}_t = \frac{m_t}{1-\beta_1^t}, \quad \hat{v}_t = \frac{v_t}{1-\beta_2^t}$$

最终参数更新为：

$$\theta_{t+1} = \theta_t - \frac{\eta \hat{m}_t}{\sqrt{\hat{v}_t} + \varepsilon}$$

Adam 的关键特点是**同时使用一阶矩（动量）与二阶矩（自适应缩放）**，通常表现出较快的初期收敛速度和较好的稳健性。

4 实验环境

本实验的软硬件环境（版本号均取自实际运行环境，见 `results/environment.txt`）：

项目	配置
操作系统	Windows
计算设备	CPU
Python	3.13.12
PyTorch	2.14.1（CPU 版）
torchvision	0.29.1（CPU 版）
NumPy	2.5.2
Pandas	3.1.0
Matplotlib	3.11.2

5 模型与实验设置

参数	取值
模型	MLP：784 → 128 → 64 → 10（ReLU 激活）
损失函数	交叉熵损失（CrossEntropyLoss）
批大小（Batch Size）	64
训练轮数（Epoch）	10
数据划分	训练集 60,000 / 测试集 10,000（Fashion-MNIST 原始划分）
数据预处理	转换为 [0, 1] 张量（ToTensor），无额外归一化
随机种子	Experiment 1/2 用 42；Experiment 3 用 42、123、2026

为保证比较公平，每个优化器在训练前都通过 `set_seed(seed)` 重新初始化随机数生成器，从而确保：

1. 模型参数初始化一致（受 seed 控制）；

2. DataLoader 的 shuffle 顺序一致（通过 `torch.Generator().manual_seed(seed)` 显式控制）。

这样在相同 seed 下，各优化器从完全相同的模型初始化出发，且每个 epoch 看到相同的 batch 顺序，比较更加严格。

6 实验设计

本实验分三组递进进行，构成完整的故事线：**统一学习率 → 发现超参数敏感性 → 合理配置 → 多次重复验证。**

6.1 Experiment 1：统一学习率

四个优化器使用完全相同的学习率 `lr = 0.001`，各训练 10 个 epoch。本实验回答的问题：**在相同学习率下，不同优化器的表现差异有多大?**

6.2 Experiment 2：各优化器合理学习率

根据各优化器的特性，为它们分别设置经验上更合理的学习率：

优化器	学习率
SGD	0.1
Momentum	0.01（momentum=0.9）
RMSProp	0.001
Adam	0.001

本实验回答的问题：**在各优化器较合理的学习率设置下，它们的实际训练表现如何?**

需要特别说明：这**不是**严格意义上的大规模超参数搜索，而是课程实验中基于经验做出的合理参数设置；同时它也不是「完全公平」的比较——因为各优化器使用的学习率不同。更准确的表述是「在各优化器较合理的学习率设置下比较其实际训练表现」。Experiment 1 与 Experiment 2 结合讨论，可以揭示一个重要认识：**优化器的性能不能脱离学习率单独评价。**

6.3 Experiment 3：多随机种子

在 Experiment 2 的学习率设置下，用 3 个随机种子（42、123、2026）分别独立训练，每个 optimizer × seed 组合训练一次，共 4 × 3 = 12 次。本实验回答的问题：**Experiment 2 的结论是否受到单次随机初始化的影响?** 通过报告 `mean ± std` 检验结论的稳健性。

7 实验结果

表 1：Experiment 1（统一学习率 lr=0.001）

优化器	学习率	准确率	训练时间(秒)	最终 Loss
SGD	0.001	69.59%	32.07	0.8363
Momentum	0.001	83.52%	33.20	0.4253
RMSProp	0.001	87.73%	34.19	0.2468
Adam	0.001	88.27%	36.67	0.2481

表 2：Experiment 2（各优化器合理学习率）

优化器	学习率	准确率	训练时间(秒)	最终 Loss
SGD	0.1	86.25%	33.09	0.2791
Momentum	0.01	87.58%	33.86	0.2763
RMSProp	0.001	87.73%	34.20	0.2468
Adam	0.001	88.27%	36.38	0.2481

表 3：Experiment 3（多随机种子，mean ± std）

优化器	准确率 (mean ± std)	最终 Loss (mean ± std)	训练时间 (mean ± std)
SGD	85.58% ± 0.84%	0.2799 ± 0.0014	33.25 ± 0.14
Momentum	87.32% ± 0.40%	0.2767 ± 0.0004	33.85 ± 0.24
RMSProp	87.25% ± 0.82%	0.2459 ± 0.0007	34.63 ± 0.12
Adam	88.13% ± 0.45%	0.2477 ± 0.0006	35.65 ± 0.13

图 1：Fashion-MNIST 样例



图 2：Experiment 2 训练 Loss 曲线

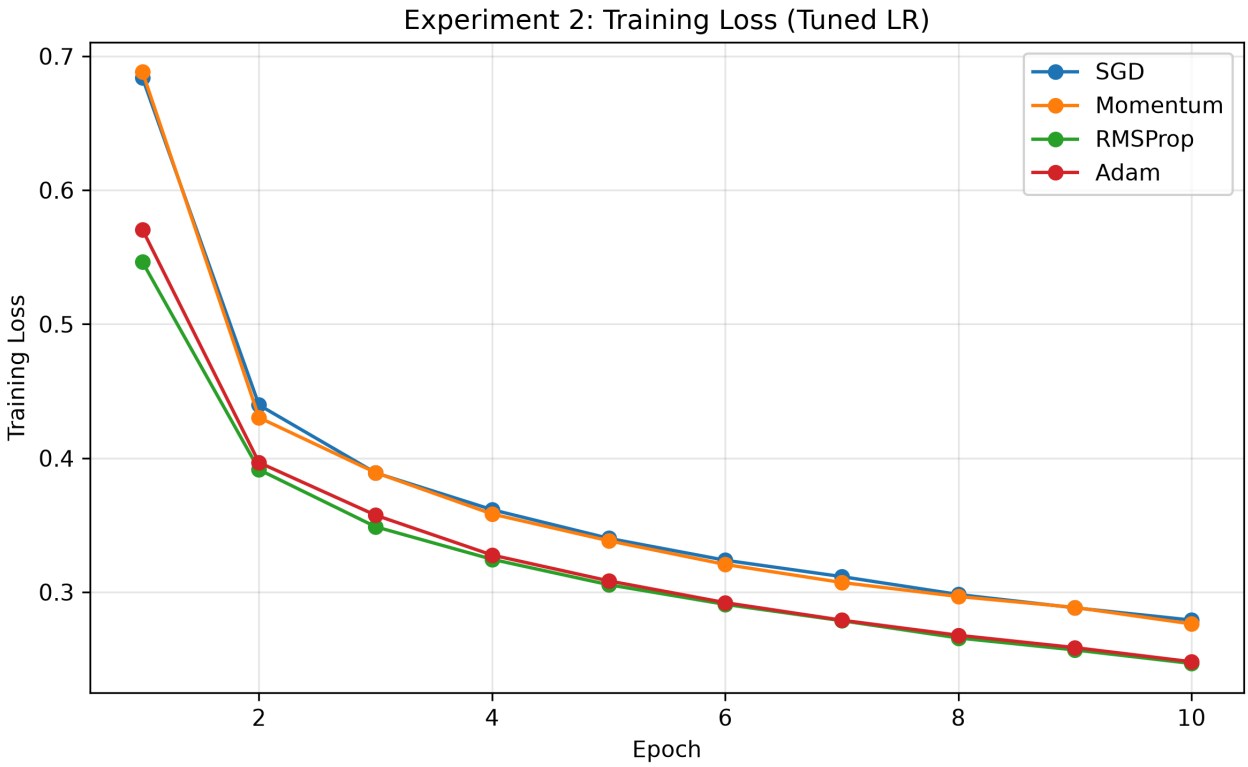


图 3：测试准确率与训练时间对比

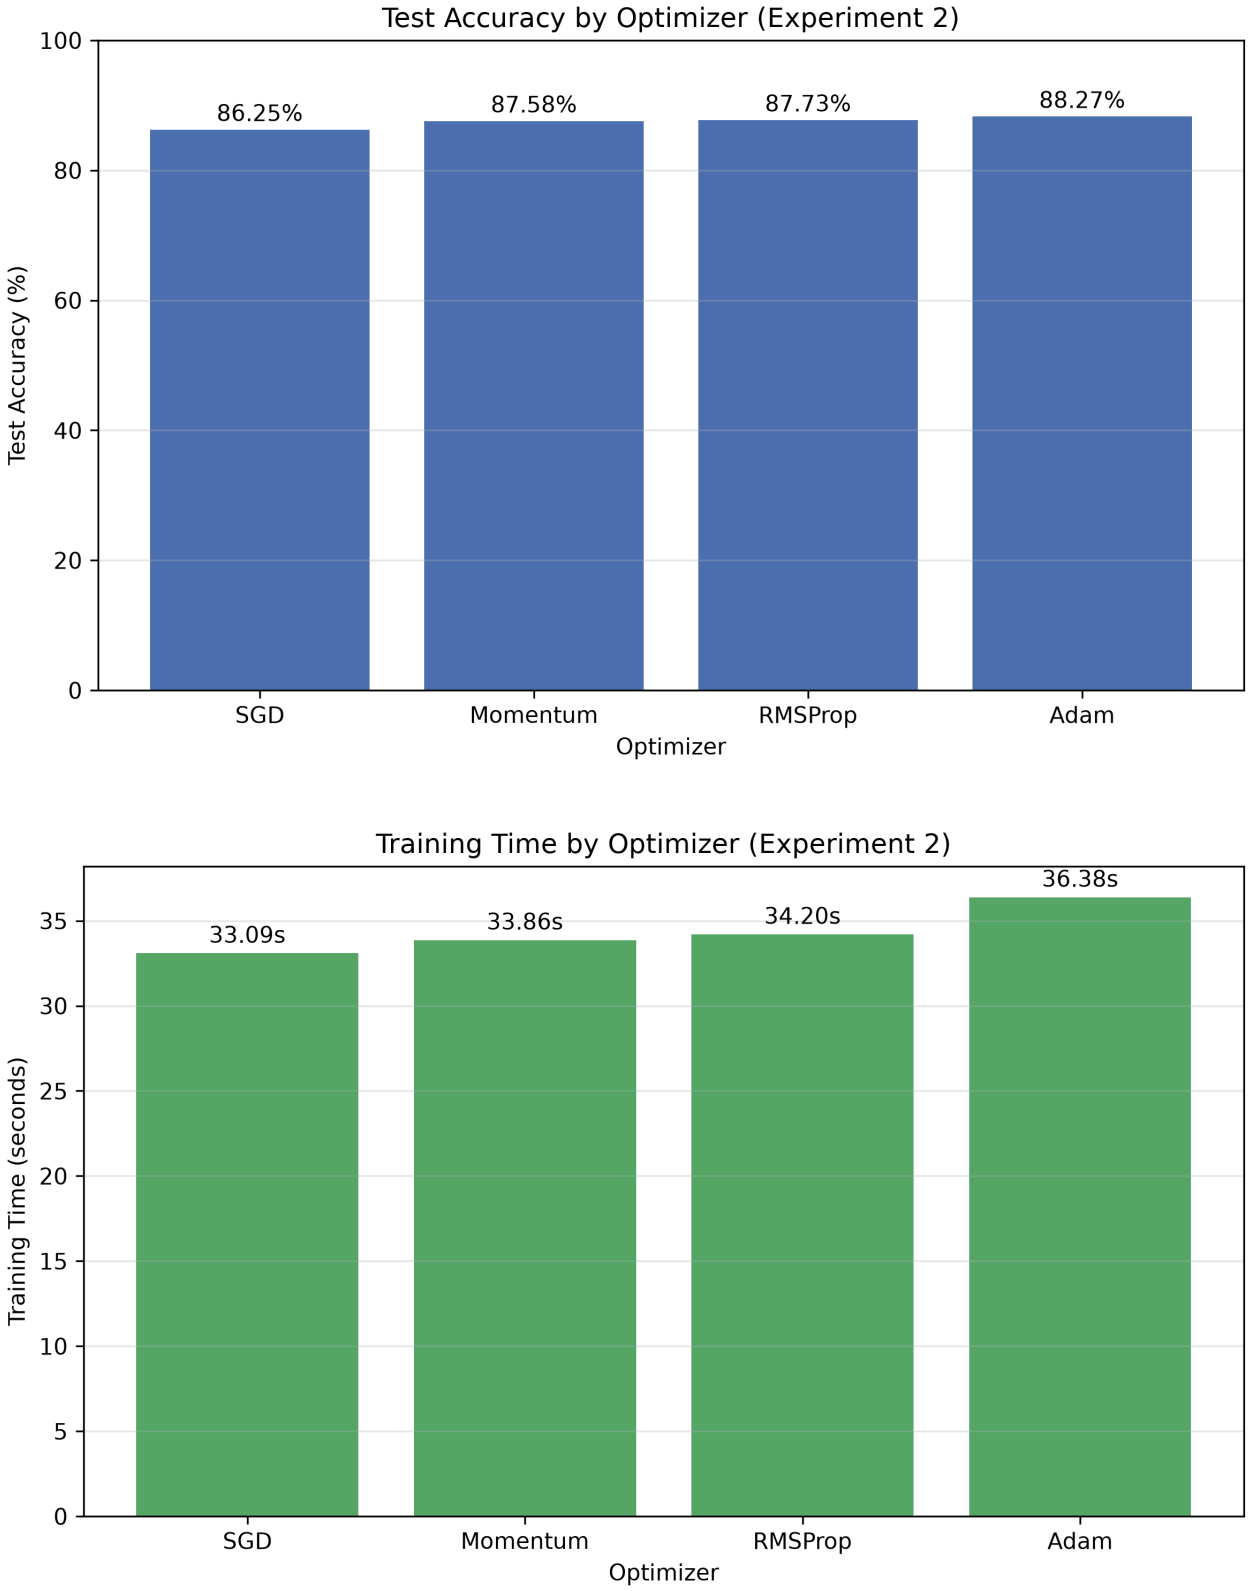


图 4：多随机种子测试准确率（mean ± std）

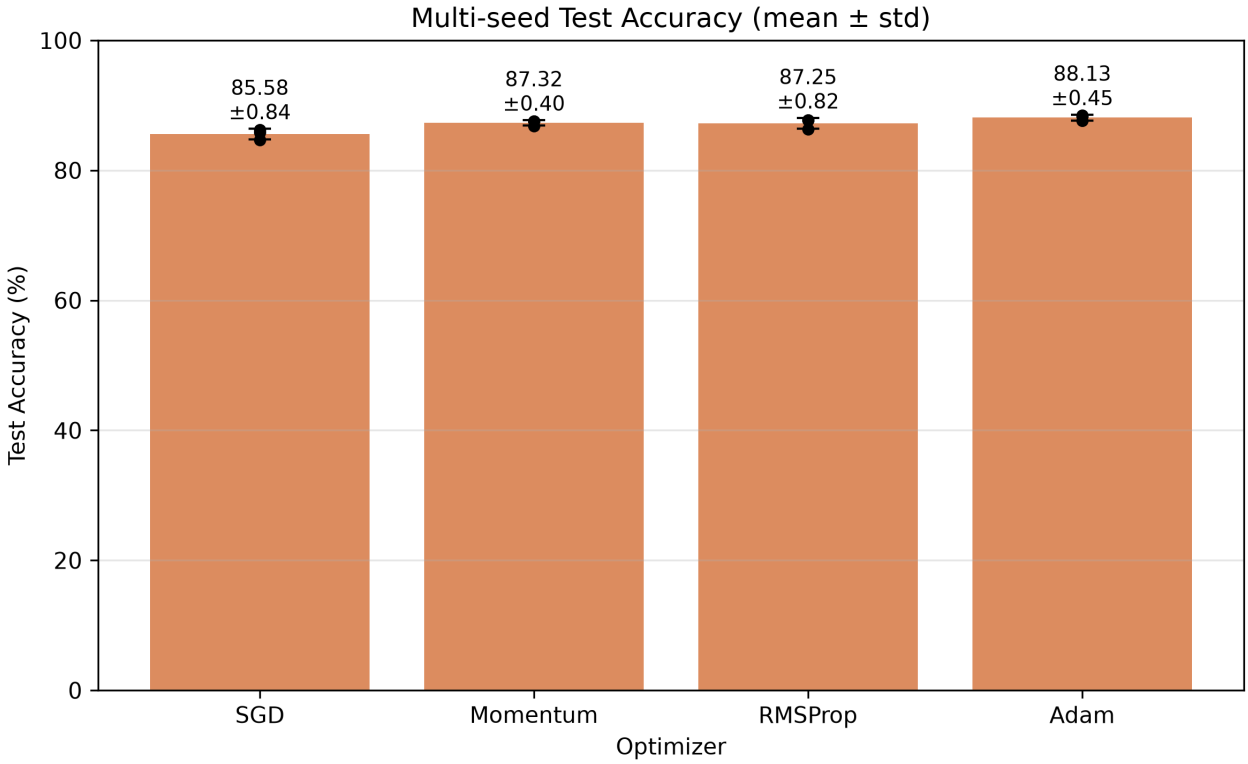
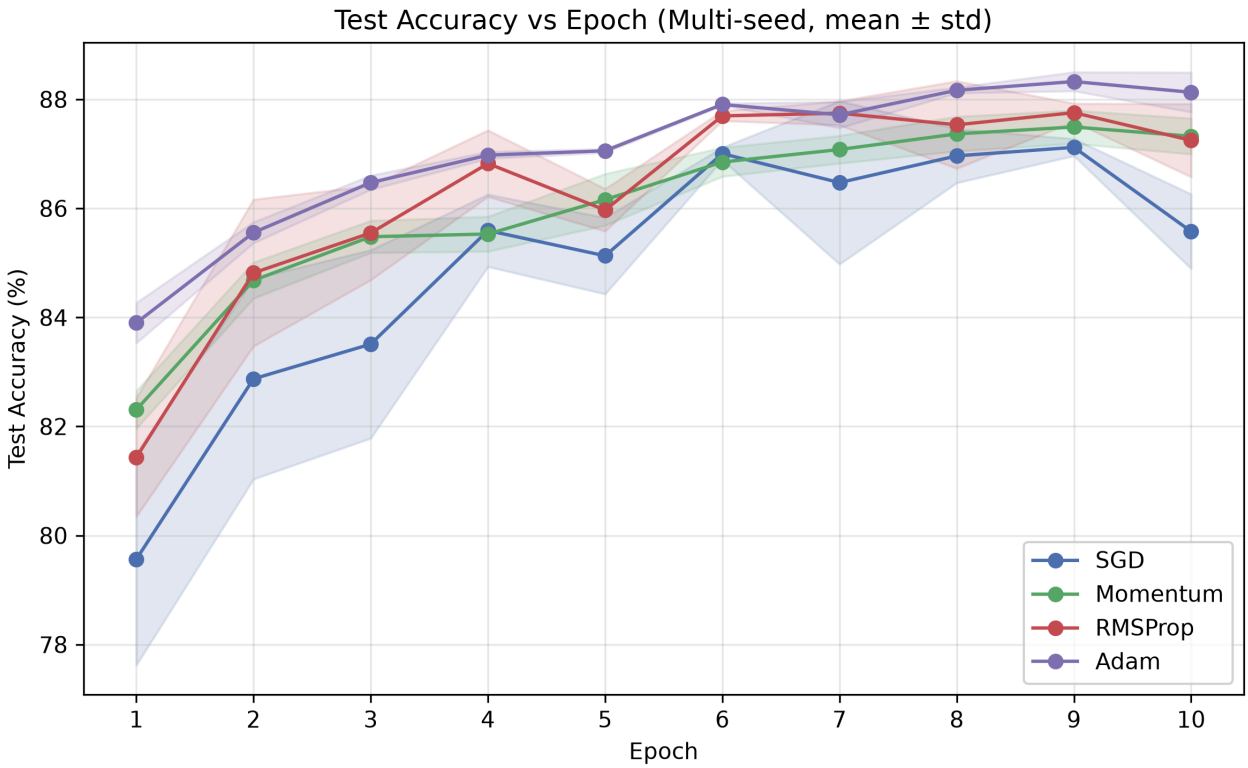


图 5：测试准确率随 Epoch 变化曲线



8 结果分析

8.1 SGD

在 Experiment 1 中，SGD 使用 `lr=0.001` 时最终准确率仅 69.59%，明显低于其他三种优化器；而在 Experiment 2 中将学习率提高到 0.1 后，准确率跃升至 86.25%，提升超过 16 个百分点。这充分说明 SGD 对学习率高度敏感——`lr=0.001` 对 SGD 而言过小，导致收敛缓慢。这一对比也说明：不能因为在某一学习率下 SGD 表现差，就得出「SGD 不如 Adam」的结论。

8.2 Momentum

Momentum 通过累积历史梯度方向，改善了 SGD 的收敛行为。在 Experiment 1 中，Momentum（83.52%）明显高于普通 SGD（69.59%）；在 Experiment 2 中，Momentum（87.58%）也高于 SGD（86.25%）。动量项的引入有助于加速收敛并抑制震荡。

8.3 RMSProp

RMSProp 在 Experiment 2 中准确率为 87.73%，与 Adam 并列最高，最终 Loss 也最低（0.2468）。其通过梯度平方的移动平均对每个参数自适应缩放学习率，在参数尺度差异较大时保持平稳更新，因此在小学习率下即可取得良好表现。

8.4 Adam

Adam 在 Experiment 2 中准确率为 88.27%，为四种优化器中最高。Adam 同时使用一阶矩与二阶矩，通常表现出较快的初期收敛速度。但在训练时间上，Adam 耗时最长（约 36.38 秒），因为需要额外维护一阶矩和二阶矩等状态，计算开销更大。需要说明：训练时间受机器性能与系统负载影响较大，本次时间差异不宜推广为普遍结论。

8.5 RMSProp vs Adam

在 Experiment 2 中，RMSProp（87.73%）与 Adam（88.27%）仅相差 0.54 个百分点。**二者非常接近，不能根据如此微小的差异断言 Adam 显著优于 RMSProp。** 这一结论需结合 Experiment 3 的多随机种子结果进一步检验。

8.6 多随机种子稳健性

Experiment 3 的结果（表 3）显示，各优化器在不同随机初始化下存在一定波动：

- **Adam** 在三种子下准确率最高（mean 88.13%），且标准差最小（±0.45%），表现最为稳健；
- **Momentum**（87.32% ± 0.40%）与 **RMSProp**（87.25% ± 0.82%）紧随其后，其中 Momentum 的标准差更小；

- **SGD** 的 mean 准确率最低（85.58%），且标准差最大（±0.84%），说明其对随机初始化更敏感。

值得注意的是，多随机种子下的排名与 Experiment 2 单次实验略有不同：单次实验中 RMSProp 与 Adam 并列最高，而多种子下 Adam 稳定领先、RMSProp 退居 Momentum 之后。**这正说明单次实验的排名可能受随机初始化影响，多随机种子实验提供了更稳健的结论。**

8.7 收敛速度

从测试准确率随 Epoch 变化的曲线（图 5）可以看出，自适应优化器（RMSProp、Adam）在训练初期收敛更快，而 SGD、Momentum 的初期准确率较低，需要更多 epoch 才能达到相近水平。

8.8 整体认识

通过三组实验可以认识到：**优化器不存在脱离超参数和任务场景的绝对优劣。**优化器的性能与学习率等超参数密切相关，不同优化器对学习率的敏感程度存在显著差异。在实际选择优化器时，应综合考虑收敛速度、最终准确率、超参数敏感性与训练成本等多方面因素。

9 实验结论

1. 四种优化器均能完成 Fashion-MNIST 图像分类任务，在合理学习率下最终准确率均达到约 86%–88%。
2. 在统一学习率（`lr=0.001`）下，SGD 收敛明显较慢，说明各优化器对学习率的敏感程度不同。
3. 调整为各优化器合理学习率后，四种优化器的性能差距明显缩小。
4. 在多随机种子下，Adam 表现最稳健（88.13% ± 0.45%），Momentum 与 RMSProp 紧随其后且非常接近，不应根据微小差异断言谁显著更优。
5. 优化器的性能不能脱离学习率单独评价，这是本实验最重要的认识之一。

10 实验局限性

1. 仅使用 Fashion-MNIST 一个数据集，结论的普适性有限。
2. 仅采用简单的 MLP 模型，未在 CNN 等更强模型上验证。
3. 学习率并非通过严格的大规模超参数搜索得到，而是基于经验的合理设置。

本实验的重点是课程层面的优化器行为比较，而非建立最先进的 Fashion-MNIST 分类器。

本报告所有实验数据均来自项目仓库中的真实运行结果（CSV 与图表），未做任何伪造或篡改。